МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА ФРАНКА

Факультет прикладної математики та інформатики
(повне найменування назва факультету)

Кафедра дискретного аналізу та інтелектуальних систем
(повна назва кафедри)

КВАЛІФІКАЦІЙНА (БАКАЛАВРСЬКА) РОБОТА

РОЗРОБКА КОМБІНОВАНОЇ СИСТЕМИ ВИЯВЛЕННЯ ДЕЗІНФОРМАЦІЇ НА ОСНОВІ ТРАНСФОРМЕРНИХ МОДЕЛЕЙ ТА ФАКТОЛОГІЧНОЇ ВЕРИФІКАЦІЇ

Виконав: студент групи ПМі–43с
спеціальності 122 «Комп'ютерні науки»
Яценко В.Т.
(підпис) (прізвище та ініціали)
Керівник Пелюшкевич О. В.
(підпис) (прізвище та ініціали)
Рецензент
(підпис) (прізвище та ініціали)

Львів – 2027

ЗМІСТ

ПЕРЕЛІК УМОВНИХ ПОЗНАЧЕНЬ І ТЕРМІНІВ 3

ВСТУП 4

1 ПОСТАНОВКА ЗАДАЧІ ТА ОГЛЯД НАЯВНИХ РІШЕНЬ 8

1.1 Огляд наявних підходів та систем 8

1.2 Постановка задачі 10

1.3 Проєктування вимог 11

2 МЕТОДИ ПОБУДОВИ КОМБІНОВАНОЇ СИСТЕМИ 13

2.1 Методи класифікації текстів та вибір трансформерної моделі 13

2.2 Пошук доказів та фактологічна перевірка 13

2.3 Поєднання результатів класифікації та фактологічної перевірки 13

2.4 Методи оцінювання якості системи 13

3 Розробка програмної системи 13

3.1 Формування та підготовка наборів даних 13

3.2 Архітектура системи та програмний інструментарій 13

3.3 Реалізація класифікаторів і фактологічної перевірки 13

3.4 Інтеграція компонентів та інтерфейс користувача 13

4 ЕКСПЕРИМЕНТАЛЬНЕ ДОСЛІДЖЕННЯ 13

4.1 Організація експериментів 13

4.2 Результати та порівняння моделей і комбінованої системи 13

4.3 Аналіз помилок та обмежень 13

ВИСНОВКИ 13

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ 14

ПЕРЕЛІК УМОВНИХ ПОЗНАЧЕНЬ І ТЕРМІНІВ

NLP (Natural Language Processing) – обробка природної мови.

FEVER (Fact Extraction and Verification) – назва набору даних і дослідницької задачі перевірки тверджень на основі текстових доказів.

BERT – модель контекстного подання тексту на основі трансформерної архітектури.

RoBERTa – модель, розроблена з удосконаленою процедурою попереднього навчання BERT.

RAG – генерація відповіді з використанням знайдених зовнішніх матеріалів.

TF-IDF (Term Frequency – Inverse Document Frequency) – спосіб числового подання тексту з урахуванням частоти сліву документі та їхньої поширеності в корпусі.

ВСТУП

Поширення новин через цифрові платформи створює потребу в інструментах перевірки достовірності інформації. Водночас недостовірний контент може мати різне походження, тому його аналіз потребує чіткого розмежування понять. У дослідженні Wardle C. і Derakhshan H. розрізняють неправдиву інформацію, поширену без наміру завдати шкоди, неправдиву інформацію, навмисно створену для заподіяння шкоди, та використання правдивих відомостей із метою заподіяння шкоди [1]. Таке розмежування важливе для автоматизованого аналізу новин, оскільки встановлення фактичної помилки та визначення наміру автора є різними завданнями.

Суспільну актуальність проблеми засвідчують результати досліджень споживання новин. За даними Digital News Report 2025 Інституту Reuters, 58 % опитаних у країнах і ринках, охоплених дослідженням, висловили занепокоєння щодо розрізнення справжньої та неправдивої інформації в онлайн-новинах [2]. Цей показник характеризує сприйняття проблеми респондентами, а не фактичну частку недостовірних повідомлень. Проте він свідчить про потребу в засобах, які допомагатимуть користувачам обґрунтовано оцінювати новинний контент.

В умовах повномасштабної війни росії проти України перевірка новин набуває особливого значення, оскільки повідомлення про безпеку, рішення органів влади та суспільні події можуть впливати на дії громадян. Це посилює потребу в інструментах перевірки україномовного контенту, які надають користувачеві докази та посилання на джерела.

Перевірка фактів передбачає пошук інформації, оцінювання джерел і зіставлення знайдених відомостей із конкретним твердженням. В огляді Guo Z. та співавторів автоматизований фактчекінг розглянуто як послідовність завдань виявлення тверджень, пошуку доказів і формування результату перевірки з відповідним обґрунтуванням [3]. Для їх розв'язування застосовують методи обробки природної мови та машинного навчання. Автоматизація окремих етапів

може допомогти опрацьовувати інформацію, перевірка якої вручну потребує значних витрат часу.

Водночас класифікація тексту за мовними ознаками не є рівнозначною перевірці наведених у ньому фактів. Як зазначено в огляді Guo Z. та співавторів, орієнтація лише на поверхневі закономірності тексту без урахування зовнішньої інформації обмежує можливість розпізнавання переконливо сформульованих неправдивих тверджень [3]. Тому результат текстового класифікатора доцільно розглядати як попередню оцінку, яку можна доповнити зіставленням із незалежними джерелами.

Приклад постановки задачі перевірки за доказами наведено в дослідженні, присвяченому набору даних FEVER. У ньому твердження відносять до категорій підтверджених, спростованих або таких, для яких недостатньо інформації; для перших двох категорій також визначають текстові докази [4]. Такий підхід дає змогу відокремити спростування твердження від ситуації, коли система не має достатніх відомостей для висновку. FEVER розглядається як приклад постановки задачі перевірки тверджень за доказами. Його англомовний набір даних у практичній частині роботи не використовується.

Актуальність роботи зумовлена потребою в засобах перевірки україномовного новинного контенту, які доповнюють оцінку текстового класифікатора доказами із зовнішніх джерел. Для користувача важливо не лише отримати результат аналізу, а й мати змогу переглянути матеріали, на яких він ґрунтується. Тому в роботі пропонується поєднати трансформерну класифікацію з пошуком і перевіркою фактологічних доказів. Експериментальне дослідження має встановити, чи покращує таке поєднання якість перевірки порівняно з використанням лише текстового класифікатора.

Метою роботи є розроблення та експериментальне оцінювання комбінованої системи виявлення ознак недостовірності україномовного новинного контенту на основі трансформерної класифікації та перевірки фактичних тверджень за зовнішніми джерелами.

Для досягнення поставленої мети необхідно проаналізувати наявні підходи до автоматизованої перевірки новинного контенту, визначити вимоги до системи та сформувати україномовний набір даних. Наступними завданнями є побудова базового класифікатора для порівняння, вибір і донавчання трансформерної моделі, підготовка корпусу доказової інформації та реалізація модуля фактологічної перевірки. Завершальний етап передбачає поєднання розроблених компонентів у програмному прототипі, проведення порівняльних експериментів та аналіз отриманих результатів і обмежень.

Об’єктом дослідження є процес автоматизованого аналізу достовірності україномовного новинного контенту.

Предметом дослідження є методи трансформерної класифікації текстів, пошуку фактологічних доказів і перевірки тверджень, а також способи поєднання результатів цих методів.

Методика дослідження передбачає використання аналізу і порівняння наукових публікацій, методів підготовки та розмітки текстових даних, донавчання попередньо навчених трансформерних моделей, інформаційного пошуку і зіставлення тверджень із доказами. Оцінювання проводиться на окремій тестовій вибірці, яку не використовують для навчання та добору параметрів, і передбачає обчислення метрик класифікації та пошуку, аналіз помилок і вимірювання часу обробки. Метою порівняльних експериментів є визначення внеску окремих компонентів у результат роботи системи.

Дослідження обмежується текстовим контентом українською мовою. Фактологічна перевірка здійснюється на основі визначеного корпусу джерел, тому її результати залежать від повноти, актуальності та якості доступної інформації. Виявлення наміру автора поширювати дезінформацію не входить до завдань системи. У межах роботи розглядається перевірюваний аспект цієї проблеми – фактична підтвердженість тверджень.

Очікуваними результатами є програмний прототип комбінованої системи, підготовлені набори даних із задокументованими правилами формування, донавчений класифікатор і результати порівняльних експериментів. Практичне

значення роботи полягає у створенні засобу підтримки попередньої перевірки україномовних новин. Його потенційними користувачами є читачі та фахівці, які аналізують інформаційні матеріали. Система має надавати відомості для подальшої перевірки, а її результати не замінюють експертного висновку.

Структура роботи передбачає чотири розділи. Перший розділ присвячено постановці задачі та аналізу наявних підходів. У другому розділі розглядаються методи класифікації, пошуку доказів, фактологічної перевірки та поєднання їхніх результатів. Третій розділ містить опис підготовки даних, архітектури й програмної реалізації системи. У четвертому розділі наводяться умови та результати експериментів, порівняльний аналіз і виявлені обмеження. У висновках узагальнюються результати виконаної роботи.

1 ПОСТАНОВКА ЗАДАЧІ ТА ОГЛЯД НАЯВНИХ РІШЕНЬ

1.1 Огляд наявних підходів та систем

Засоби перевірки новинного контенту відрізняються рівнем автоматизації та способом формування висновку. Фактчекінгові організації залучають фахівців для аналізу повідомлень і пошуку доказів. Інтерактивні сервіси допомагають користувачам самостійно оцінювати інформацію, а автоматизовані системи застосовують методи машинного навчання та інформаційного пошуку.

Серед українських фактчекінгових проєктів відомим є StopFake, діяльність якого спрямована на перевірку повідомлень і викриття пропаганди, пов’язаної з Україною. Проєкт здійснює моніторинг інформаційного простору та публікує спростування з поясненнями й посиланнями на джерела [5]. Перевагою проєкту є обґрунтованість висновків, а обмеженням – необхідність опрацювання повідомлень фахівцями.

VoxCheck займається перевіркою суспільно значущих повідомлень і фактологічних висловлювань політиків. Аналіз ґрунтується на відкритих джерелах, а результати супроводжуються поясненнями. Проєкт використовує кілька вердиктів, серед яких є правда, неправда, маніпуляція та перебільшення [6]. Такі вердикти дозволяють оцінювати не лише фактичну правильність, а й викривлення контексту повідомлення.

Фактчекінговий напрям Ґвара Медіа передбачає перевірку інформації, яку користувачі можуть надсилати через бот «Перевірка». Методологія охоплює кілька результатів оцінювання, зокрема правду, фейк, напівправду та недостатність доказів [7]. Такий спосіб взаємодії спрощує звернення користувачів, проте перевірка може потребувати участі фахівців.

Поряд з експертною перевіркою існують інструменти, які залучають до оцінювання самого користувача. Прикладом є «Калькулятор фейків» на сайті FakeCheck.in.ua. Він пропонує оцінити повідомлення через відповіді на п’ять запитань [8]. Результат залежить від того, наскільки правильно користувач відповідає на запитання та оцінює повідомлення.

Спільною рисою розглянутих рішень є участь людини в оцінюванні повідомлення. Для автоматизації попереднього аналізу текстів застосовують методи машинного навчання. У роботі V. Pérez-Rosas та співавторів розглянуто мовні характеристики правдивих і неправдивих матеріалів та проведено експерименти з їх класифікацією [9]. Цей напрям дозволяє опрацьовувати тексти без окремої ручної перевірки кожного повідомлення. Проте класифікатор виявляє закономірності тексту, тому його прогноз не є безпосереднім доказом достовірності наведених фактів. Результати такої класифікації залежать від даних, на яких навчалася модель. Asr F. T., Taboada M. з Університету Саймона Фрейзера розглядають якість наборів даних і тематичні відмінності між правдивими та неправдивими матеріалами [10]. Це важливо для оцінювання моделей, оскільки тематичні особливості вибірки можуть впливати на прогнозований клас.

Для врахування контексту повідомлень застосовують трансформерні моделі. BERT формує контекстні представлення тексту й допускає донавчання для конкретного завдання [11]. Розвитком цього підходу є RoBERTa, у якій удосконалено процедуру попереднього навчання [12]. Проте навіть контекстна класифікація не передбачає безпосередньої перевірки повідомлення за зовнішніми джерелами. Залучення зовнішніх джерел дозволяє доповнити аналіз тексту інформацією про перевірюване твердження. Одним із підходів до використання таких матеріалів є RAG, який поєднує їх пошук із генеруванням відповіді [13]. У задачі перевірки новин це створює можливість формувати пояснення з використанням знайдених документів. Обмеженнями залишаються якість пошуку та ризик висновку, який недостатньо обґрунтований наведеними матеріалами.

Наявні рішення забезпечують експертну перевірку, підтримку користувача або автоматичне оцінювання тексту. Для розроблюваної системи доцільно дослідити поєднання трансформерної класифікації з перевіркою тверджень за зовнішніми джерелами. Це дозволить доповнювати прогноз класифікатора доказовою інформацією та повідомляти про випадки, коли її недостатньо для висновку.

1.2 Постановка задачі

Метою роботи є розроблення та експериментальне оцінювання комбінованої системи виявлення ознак недостовірності україномовного новинного контенту на основі трансформерної класифікації та перевірки фактичних тверджень за зовнішніми джерелами.

Текстовий класифікатор має формувати попередню оцінку повідомлення, а фактологічний модуль – шукати релевантні матеріали та визначати, чи підтверджують вони перевірюване твердження, спростовують його або не містять достатньої інформації. Результати обох компонентів необхідно поєднати для формування підсумкової оцінки з поясненням.

Для досягнення поставленої мети необхідно виконати такі завдання:

1) Сформувати україномовний набір даних, виконати очищення, мовний відбір і видалення дублікатів. Задокументувати походження міток та розділити дані на навчальну, валідаційну й тестову вибірки з урахуванням пов’язаних матеріалів.
2) Реалізувати базовий класифікатор на основі логістичної регресії та TF-IDF векторизації для подальшого порівняння.
3) Обрати й донавчити трансформерну модель із підтримкою української мови та порівняти її результати з базовим класифікатором.
4) Підготувати корпус доказової інформації та реалізувати пошук релевантних матеріалів зі збереженням посилань на джерела.
5) Реалізувати зіставлення тверджень зі знайденими доказами та поєднання результатів фактологічної перевірки й класифікації.
6) Створити програмний прототип з інтерфейсом введення тексту й перегляду результатів.
7) Провести порівняльні експерименти, оцінити якість класифікації та пошуку, час обробки й основні помилки системи.

Вхідними даними є україномовне повідомлення або окреме фактичне твердження. Результат має містити оцінку класифікатора, висновок фактологічної

перевірки та посилання на знайдені матеріали. Недостатність доказів не повинна автоматично означати неправдивість повідомлення.

Робота обмежується текстовим контентом і не передбачає визначення наміру автора. Система призначена для підтримки попередньої перевірки інформації та не замінює експертного висновку.

1.3 Проєктування вимог

Вимоги до системи визначають її функціональні можливості, характеристики та обмеження. Основним користувачем є людина, яка подає україномовне повідомлення для попередньої перевірки та переглядає отриманий результат.

Основні сценарії взаємодії представлено на діаграмі прецедентів (рисунок 1.1). Користувач вводить текст, запускає перевірку, переглядає оцінки компонентів системи й підсумковий висновок, а також ознайомлюється зі знайденими доказами та джерелами.



Рисунок 1.1 – Діаграма прецедентів комбінованої системи

Функціональні вимоги описують дії, які система має виконувати під час перевірки повідомлення, від введення тексту до відображення результатів. До них належать такі вимоги:

1) Введення україномовного повідомлення або окремого твердження через текстове поле вебінтерфейсу.

2) Перевірка коректності введення з повідомленням про порожній текст або перевищення допустимої довжини.
3) Класифікація тексту трансформерною моделлю з відображенням прогнозованого класу та оцінки впевненості моделі.
4) Пошук у підготовленому корпусі матеріалів, релевантних перевірюваному твердженню.
5) Зіставлення твердження із знайденими матеріалами для визначення підтвердження, спростування або недостатності доказів.
6) Поєднання результатів класифікації та фактологічної перевірки з окремим відображенням оцінок обох компонентів.
7) Відображення пояснення результату, доказових фрагментів і посилань на відповідні джерела.

Нефункціональні вимоги стосуються зручності взаємодії із системою, її надійності та умов виконання перевірки. Вони визначають такі вимоги до реалізації:

1) Інтерфейс має бути україномовним, містити зрозумілі назви елементів і повідомляти про перебіг обробки.
2) Некоректне введення або помилка окремого компонента не повинні спричиняти аварійне завершення роботи. Якщо фактологічна перевірка недоступна, користувач має отримати відповідне повідомлення.
3) Прогноз класифікатора потрібно відрізняти від результату перевірки за доказами. Оцінка впевненості моделі не повинна подаватися як імовірність фактичної правдивості повідомлення.
4) Час класифікації, пошуку й фактологічної перевірки необхідно вимірювати окремо на визначеній конфігурації обладнання.
5) Компоненти класифікації, пошуку та верифікації мають допускати заміну без повного перероблення системи.
6) Репозиторій має містити інструкцію запуску, перелік залежностей та конфігурації проведених експериментів.

Сформульовані вимоги є основою для побудови архітектури, реалізації програмного прототипу та перевірки його роботи.

2 МЕТОДИ ПОБУДОВИ КОМБІНОВАНОЇ СИСТЕМИ

2.1 Методи класифікації текстів та вибір трансформерної моделі

2.2 Пошук доказів та фактологічна перевірка

2.3 Поєднання результатів класифікації та фактологічної перевірки

2.4 Методи оцінювання якості системи

3 РОЗРОБКА ПРОГРАМНОЇ СИСТЕМИ

3.1 Формування та підготовка наборів даних

3.2 Архітектура системи та програмний інструментарій

3.3 Реалізація класифікаторів і фактологічної перевірки

3.4 Інтеграція компонентів та інтерфейс користувача

4 ЕКСПЕРИМЕНТАЛЬНЕ ДОСЛІДЖЕННЯ

4.1 Організація експериментів

4.2 Результати та порівняння моделей і комбінованої системи

4.3 Аналіз помилок та обмежень

ВИСНОВКИ

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ

1. Wardle C., Derakhshan H. Information Disorder: Toward an Interdisciplinary Framework for Research and Policy Making. Council of Europe, 2017. [Електронний ресурс] – Режим доступу: https://rm.coe.int/information-disorder-report-november-2017/1680764666 (дата звернення: 28.09.2026)
2. Reuters Institute for the Study of Journalism. Overview and Key Findings of the 2025 Digital News Report. 2025. [Електронний ресурс] – Режим доступу: https://reutersinstitute.politics.ox.ac.uk/digital-news-report/2025/dnr-executive-summary (дата звернення: 28.09.2026)
3. Guo Z., Schlichtkrull M., Vlachos A. A Survey on Automated Fact-Checking. Transactions of the Association for Computational Linguistics. Vol 10. 2022. [Електронний ресурс] – Режим доступу: https://aclanthology.org/2022.tacl-1.11/ (дата звернення: 28.09.2026)
4. Thorne J., Vlachos A., Christodoulopoulos C., Mittal A. FEVER: a Large-scale Dataset for Fact Extraction and VERification. Proceedings of NAACL-HLT 2018. [Електронний ресурс] – Режим доступу: https://aclanthology.org/N18-1074/ (дата звернення: 26.10.2026)
5. StopFake. Про нас. [Електронний ресурс] – Режим доступу: https://www.stopfake.org/uk/pro-nas/ (дата звернення: 26.10.2026)
6. VoxCheck. Про VoxCheck. [Електронний ресурс] – Режим доступу: https://voxcheck.voxukraine.org/ (дата звернення: 26.10.2026)
7. Ґвара Медіа. Методологія фактчекінгу Ґвара Медіа. [Електронний ресурс] – Режим доступу: https://gwaramedia.com/metodologiya-faktchekingu-perevirka/ (дата звернення: 26.10.2026)
8. Міністерство культури та інформаційної політики України. Українці зможуть легко відрізняти фейки від правдивих новин завдяки «Калькулятору фейків». [Електронний ресурс] – Режим доступу: https://www.kmu.gov.ua/news/ukraintsi-zmozhut-lehko-vidrizniaty-feiky-vid-pravdyvykh-novyn-zavdiaky-kalkuliatoru-feikiv (дата звернення: 26.10.2026)

9. Pérez-Rosas V., Kleinberg B., Lefevre A., Mihalcea R.. Automatic Detection of Fake News. Preceding of the 27th International Conference on Computational Linguistics (COLING 2018). 2018. [Електронний ресурс] – Режим доступу: https://aclanthology.org/C18-1287/ (дата звернення: 26.10.2026)
10. Asr F. T., Taboada M. Big Data and quality data for fake news and misinformation detection. Big Data & Society. 2019. Vol.6, №1 [Електронний ресурс] – Режим доступу: https://journals.sagepub.com/doi/10.1177/2053951719843310 (дата звернення: 26.10.2026)
11. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. Proceedings of NAACL-HLT 2019. 2019. [Електронний ресурс] – Режим доступу: https://aclanthology.org/N19-1423/ (дата звернення: 26.10.2026)
12. Liu Y., Ott M., Goyal N. et al. RoBERTa: A Robustly Optimized BERT Pretraining Approach. arXiv:1907.11692. 2019 [Електронний ресурс] – Режим доступу: https://arxiv.org/abs/1907.11692 (дата звернення: 26.10.2026)
13. Lewis P., Perez E., Piktus A. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems 33 (NeurlPS 2020). 2020. [Електронний ресурс] – Режим доступу: https://arxiv.org/abs/2005.11401 (дата звернення: 26.10.2026)